Thực nghiệm Đánh giá Đặc trưng Ngoại lai & So sánh MICE vs XGBoost

Sinh viên: Đỗ Minh Phúc

Ngày 4 tháng 7 năm 2026

1 Giới thiệu

2 Công việc thực hiện

3 Kết quả Thực nghiệm

4 Kết luận

Công việc thực hiện

- **Thách thức trong dự báo chất lượng nước biển:**
  - Các trạm quan trắc (sensor) giới hạn về số lượng
  - Cần đầy đủ các chỉ số quan trắc để đánh giá chất lượng nước biển
- **Bài toán nội suy & phóng chiếu:**
  - **Phase 1 (Local Imputation):** Lấp đầy dữ liệu bị thiếu hụt ngay tại vị trí đặt trạm (suy diễn từ các chỉ số cảm biến cơ bản).
  - **Phase 2 (Spatial Extrapolation):** Phóng chiếu dữ liệu xuyên không gian từ một Trạm Gốc (Anchor) sang vùng biển không có trạm (Target).
- **Khuyết điểm của mô hình tuyến tính (MICE):** Khó có khả năng nắm bắt được quy luật phi tuyến do thời tiết và vi khí hậu tác động.

1 Giới thiệu

2 Công việc thực hiện

3 Kết quả Thực nghiệm

4 Kết luận

Giải pháp: Làm giàu dữ liệu (Data Enrichment)

- **Ý tưởng cốt lõi:** Cung cấp thêm "bối cảnh môi trường" cho mô hình Học máy (XGBoost) để nhận diện phương sai.
- **Khai thác dữ liệu ngoại lai (Exogenous Features):**
  - **Độ sâu (Depth):** Trích xuất và nội suy từ bản đồ vệ tinh GIS (Yếu tố bất biến theo thời gian - Time-invariant).
  - **Thời tiết:** Tích hợp lượng Mưa, Sức Gió, Sóng (Yếu tố biến thiên theo thời gian - Time-variant). Dữ liệu được tính trung vị (Median) theo từng quý để triệt tiêu nhiễu.
- **Thiết kế Thử nghiệm (Ablation Study):**
  - So sánh cấu hình Base (chỉ dùng cảm biến gốc) vs Cấu hình có Thời tiết.
  - Đối chứng sức mạnh của **XGBoost** so với Baseline của nhóm là **MICE** (Linear BayesianRidge Imputer).

1 Giới thiệu

2 Công việc thực hiện

3 Kết quả Thực nghiệm

4 Kết luận

Phase 1: Local Imputation (Mô hình Toàn cục - N=216)

- **Mục tiêu:** Đánh giá khả năng suy diễn thông số nước khi gom chung dữ liệu toàn Vịnh Hải Phòng.
- **Phát hiện:** Yếu tố thời tiết (Thời gian) giúp cải thiện đáng kể khả năng dự báo của XGBoost, nhưng không ảnh hưởng nhiều đến MICE.

Cấu hình	XGB DO	XGB Salinity	XGB PO4	MICE DO	MICE Salinity	MICE PO4
Base (Có Time Feat)	0.365	0.784	0.302	0.133	0.519	0.261
Base + Thời tiết	**0.404**	**0.849**	**0.370**	0.131	0.510	0.274

**Các chỉ số Sinh học (Coliform) và Kim loại nặng (Cd, Pb, Zn...) có $R^2 < 0$, buộc phải dùng thuật toán Trung vị (Median Fallback).*

Phase 2: Nội suy Đa trạm - Lựa chọn Trạm Gốc

Thực trạng Hệ thống Cảm biến:

- Số liệu từ hàng chục điểm quan trắc thu thập theo đợt rời rạc (1 quý/lần).
- Chỉ có **01 Trạm Cảm biến IoT** (Trạm Làng bè anh Toàn) truyền dữ liệu liên tục mỗi 3 phút.
- **Quyết định Kiến trúc:** Chọn trạm này làm **Trạm Gốc (Anchor Station - NB1)** để phóng chiếu ra toàn mạng lưới Vịnh thay vì cắm IoT ở mọi nơi (giảm chi phí).

Phase 2: Bóc tách Từng Trạm (Chỉ số Độ mặn)

- **Thực trạng ($R^2 < 0$):** Việc thêm nhiều trường thông tin thời tiết vào tập dữ liệu quá nhỏ (16 mẫu) đã làm mất khả năng tổng quát hóa, dẫn đến sai số khổng lồ khi dự đoán ở các trạm khác.
- **So sánh trạm:** Hầu hết kết quả của các trạm đều giảm đi khi thêm biến thời tiết

Trạm Đích	XGB Base	XGB + Thời tiết
NB4 (Vịnh Hạ Long)	**0.739**	0.619
NB3 (Cẩm Phả)	**0.451**	-0.458
NB15 (Cát Bà)	**0.441**	-1.170
NB16 (Lạch Huyện)	**0.249**	0.039

Phase 2: Nội suy Đa trạm - Đánh giá Phóng chiếu Đa chỉ số

Bảng 1: Hiệu năng dự đoán Salinity, DO và PO4 tại các Trạm Ảo mục tiêu

Trạm Mục tiêu	Khu vực	Số Mẫu	R^2 (Salinity)	R^2 (DO)	R^2 (PO4)
NB4	Vịnh Hạ Long	16	**0.739**	-0.980	-0.231
NB3	Cẩm Phả	16	**0.451**	-1.087	-7.920
NB15	Cát Bà	16	**0.441**	-1.751	-5.377
NB16	Lạch Huyện	16	**0.249**	-2.153	-3.382

Nhận xét:

- **Salinity (Độ mặn):** Các trạm có R^2 khá (đặc biệt NB4 đạt 0.74) chứng tỏ tính chất lan truyền vật lý hải dương học tốt, có thể dự đoán sang trạm khác khá tốt.
- **DO, PO4 (Sinh hóa):** Kém hơn hẳn (R^2 âm rất sâu) vì các chỉ số này biến thiên cục bộ rất mạnh do xả thải và vi khí hậu. Bắt buộc phải dùng nội suy địa thống kê (Kriging).

1 Giới thiệu

2 Công việc thực hiện

3 Kết quả Thực nghiệm

4 Kết luận

Kết luận

- **Thời tiết quyết định độ mặn (Khi đủ dữ liệu):** Nếu hệ thống có đủ mẫu (Data-rich), các yếu tố Mưa/Gió cung cấp tín hiệu cực tốt giúp XGBoost đạt hiệu năng xuất sắc ($R^2 = 0.88$) ở Phase 1. Thuật toán tuyến tính (MICE) hoàn toàn thất bại.
- **Cạm bẫy Phóng chiếu Không gian (Phase 2):**
  - Khi phóng chiếu từ 1 trạm gốc IoT (chỉ có 16 quý dữ liệu), tuyệt đối không lạm dụng việc thêm biến (như Thời tiết).
  - Hiện tượng **Overfitting** (Curse of Dimensionality) sẽ xảy ra, khiến mô hình học vẹt thời tiết cục bộ và mất khả năng tổng quát hóa sang trạm đích.
- **Chiến lược Tối ưu:**
  - **Phase 1:** Dùng XGBoost + Thời tiết (Tận dụng sức mạnh phi tuyến).
  - **Phase 2:** Chỉ dùng mô hình Base (Kèm mã hóa chu kỳ thời gian) để bảo toàn tính ổn định khi nội suy xuyên không gian.

Xin cảm ơn