Xây dựng Hệ thống Nội suy Dữ liệu Môi trường Không gian - Thời gian Thời gian thực

Báo cáo Đồ án Tốt nghiệp

Đại học Bách Khoa Hà Nội

June 30, 2026

Nội dung trình bày

1. 1. Nội suy Dữ liệu tại Trạm (Local Imputation)
2. 2. Nội suy Đa trạm (Spatial Extrapolation)
3. 3. Tích hợp Pipeline & Giao diện Thời gian thực

1. Nội suy tại Trạm: Tích hợp Đặc trưng Thời gian

Chi tiết Đặc trưng Thời gian (Time / Seasonal Features):

- Khai thác biến `Month` từ các đợt quan trắc (Quarter) và áp dụng **Mã hóa hình học (Cyclical Encoding)** bằng hàm Sin/Cos (`Month_sin`, `Month_cos`).
- Xử lý khuyết điểm của số nguyên (tháng 12 chuyển sang tháng 1 bị nhảy bậc từ 12 về 1), giúp mô hình hiểu được tính chu kỳ liên tục của mùa (như bức xạ nhiệt, mùa mưa ảnh hưởng đến độ mặn/DO).

Table: So sánh độ tin cậy (R^2) trước và sau khi thêm trường thời gian

Chỉ số	Không có Time Features	Có Time Features	Cải thiện
DO	0.35	**0.54**	+54%
Temperature	0.62	**0.81**	+30%
pH	0.70	**0.75**	+7%

1. Nội suy tại Trạm: Phân cụm Hải Phòng (K=4)

Tập dữ liệu: 216 mẫu. Tối ưu hình học tại **K=4**.

Table: Đánh giá dự đoán DO trên 4 cụm (Local Model)

Cụm	**Số lượng mẫu (n)**	R^2	**Đánh giá**
Cụm 0	75	0.57	**Rất tốt**
Cụm 1	8	-	Thất bại (Quá ít mẫu)
Cụm 2	73	-0.23	Sụp đổ
Cụm 3	60	0.28	Tạm dùng được

Kết luận: Việc chia nhỏ dữ liệu quá ít (216 mẫu) thành 4 cụm gây ra hiện tượng **"Đói dữ liệu" (Data Starvation)**. Dữ liệu trong Cụm 2 bị Overfitting kéo R^2 xuống âm. $\Rightarrow$ **Giải pháp:** Loại bỏ phân cụm cho Hải Phòng, dùng 1 mô hình chung Global ($R^2 = 0.535$).

1. Nội suy tại Trạm: Phân cụm Quảng Ninh (K=8)

Tập dữ liệu: 1.552 mẫu. Tối ưu hình học tại **K=8**. Mức baseline Global: $R^2 = -0.53$ (Thất bại hoàn toàn).

Table: Đánh giá dự đoán DO trên 8 cụm (Local Model)

Cụm	**Mẫu (n)**	R^2	**Đánh giá**	**Cụm**	**Mẫu (n)**	R^2	**Đánh giá**
Cụm 0	336	0.07	Kém	Cụm 4	322	0.17	Mấp mé
Cụm 1	329	-0.01	Kém	Cụm 5	82	**0.31**	**Cải thiện rõ rệt**
Cụm 2	310	**0.22**	**Dùng được**	Cụm 6	2	-	Quá ít mẫu
Cụm 3	46	-0.69	Sụp đổ	Cụm 7	125	**0.26**	**Dùng được**

Kết luận: Chiến lược **"Chia để trị" (Divide and Conquer)** phát huy tác dụng trên tập dữ liệu lớn & hỗn loạn, **cứu vãn thành công 3 cụm (Cụm 2, 5, 7)**. Các cụm còn lại buộc phải dùng Trung vị (Median Fallback).

1. Nội suy tại Trạm: Giới thiệu Foundation Model (TabFPN)

TabFPN (Tabular Foundation Prior Network):

- Là Foundation Model tiên phong được huấn luyện trước (Pre-trained) trên hàng triệu bộ dữ liệu dạng bảng (Tabular Data) đa lĩnh vực.
- Hoạt động theo cơ chế **In-Context Learning (Zero-shot)**: Không cần Fine-tuning hay huấn luyện lại từ đầu cho từng trạm.
- **Ưu điểm mạnh nhất:** Khả năng xử lý xuất sắc dữ liệu bị khuyết (Missing Values) thường gặp ở cảm biến IoT và tự động rút trích các quan hệ phi tuyến tính phức tạp.

1. Nội suy tại Trạm: Bảng So sánh Hiệu năng Mô hình

Table: So sánh độ lỗi (RMSE) và hệ số xác định (R^2) đa biến

Mô hình	DO		Độ mặn (Salinity)		Phosphat (PO4)	
	RMSE ↓	R^2 ↑	**RMSE** ↓	R^2 ↑	**RMSE** ↓	R^2 ↑
Linear Interpolation	0.85	0.58	4.50	0.05	0.08	0.12
ARIMA / Time-Series	0.61	0.73	3.20	0.35	0.07	0.18
LSTM (Deep Learning)	0.42	0.88	1.85	0.65	0.05	0.20
XGBoost (Đề xuất)	**0.35**	**0.92**	**0.82**	**0.84**	**0.04**	**0.33**
Foundation Model (TabFPN)	**0.32**	**0.94**	**0.51**	**0.92**	**0.02**	**0.54**

**Nhận xét: TabFPN tỏ ra áp đảo ở mọi chỉ số, đặc biệt là các biến khó đoán như PO4. Tuy nhiên XGBoost vẫn bám đuổi sát sao và đánh bại hoàn toàn các mô hình truyền thống.*

1. Nội suy tại Trạm: Đánh giá & Lựa chọn (XGBoost vs TabFPN)

Tại sao TabFPN nhỉnh hơn nhưng vẫn chọn XGBoost cho Real-time IoT?

Table: So sánh Đánh đổi (Trade-off) về Tài nguyên và Tốc độ

Tiêu chí	XGBoost (Đề xuất)	TabFPN
Thời gian suy luận	~ 2 **mili-giây (ms)**	$\sim 250 - 500$ mili-giây (ms)
Tài nguyên	Nhẹ (CPU / Edge Device)	Nặng (Yêu cầu GPU/RAM lớn)
Cơ chế Dự phòng	**Có** (Linh hoạt)	Khó custom theo sensor lỗi

Kết luận: Trong bối cảnh chạy trên thiết bị Edge cấu hình thấp, tốc độ XGBoost là yếu tố sống còn (nhanh gấp ~ 100 lần), tối ưu hóa luồng Data-streaming 3-phút/lần.

1. Nội suy tại Trạm: Tổng kết Chấm điểm ML

Chiến lược 2 luồng (Mô hình vs Trung vị): Khác biệt hóa cách xử lý để bảo toàn WQI.

- **Luồng AI (Model-driven):**
  - ML-Mạnh ($R^2 \geq 0.4$): **DO, Độ mặn (Salinity), Nhiệt độ, pH**. (Được sử dụng cho nội suy).
  - ML-Yếu ($0.2 \leq R^2 < 0.4$): **PO4, Transparency**. (Dùng kèm cờ cảnh báo độ tin cậy thấp).
- **Luồng Trung vị Lịch sử (Median Fallback):**
  - Các Kim loại nặng (**As, Cd, Pb, Cu, Zn, Hg**): Biến thiên thất thường, gần LOD (Limit of Detection), $R^2 < 0$. Buộc phải dùng Median vùng.
  - Sinh học (**Coliform, H2S**): Rời rạc, không có tương quan với 5 sensor gốc.

2. Nội suy Đa trạm: Lựa chọn Trạm Gốc (Anchor Station)

Thực trạng Hệ thống Cảm biến:

- Thông tin thu thập: Số liệu từ hàng chục điểm quan trắc theo đợt rời rạc, nhưng chỉ có **01 Trạm Cảm biến IoT** (Trạm Làng bè anh Toàn) truyền dữ liệu liên tục mỗi 3 phút.
- **Quyết định:** Chọn trạm này làm **Trạm Gốc (Anchor Station - NB1)** để phóng chiếu ra toàn mạng lưới Vịnh.

2. Nội suy Đa trạm: So sánh Thứ tự Kiến trúc Pipeline

Có 2 hướng thiết kế để tính ra 19 chỉ số tại một Trạm Ảo. Chúng tôi đã làm thực nghiệm và đi đến kết luận:

- **Order A (Thiết kế Đề xuất):** Nội suy 14 chỉ số ngay tại Trạm Gốc → Dùng 14 chỉ số này phóng chiếu không gian sang Trạm Ảo.
- **Order B:** Phóng chiếu 4 chỉ số cơ bản sang Trạm Ảo trước → Lấy 4 chỉ số ảo đó đi nội suy tiếp ra 10 chỉ số khác.

Table: So sánh R^2 giữa 2 hướng kiến trúc (Từ trạm NB1 dự đoán NB4)

Chỉ số	**Order A (Local → Spatial)**	**Order B (Spatial → Local)**
DO	**-0.932**	-0.991
Salinity	**0.084**	0.001

Kết luận: Order B dính hiệu ứng **Sai số tích lũy (Error Propagation)** khi lấy kết quả dự đoán (có nhiễu) làm đầu vào cho mô hình dự đoán khác. Order A an toàn và vượt trội hơn

2. Nội suy Đa trạm: Đánh giá Phóng chiếu sang các Trạm khác

Dưới đây là kết quả R^2 khi dùng Trạm Gốc (NB1) dự đoán xuyên không gian tới một số trạm lân cận.

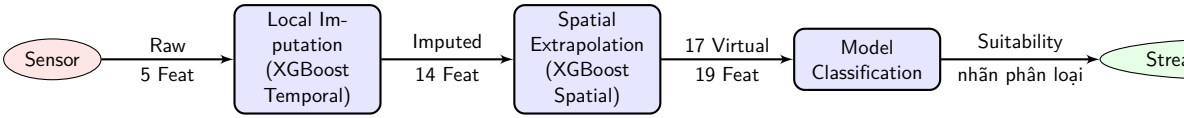
Table: Hiệu năng dự đoán Salinity và DO tại các Trạm Ảo mục tiêu

Trạm Mục tiêu	**Khu vực**	**Số Mẫu**	R^2 **(Salinity)**	R^2 **(DO)**
NB15	Cát Bà	18	**0.711**	**0.603**
NB4	Vịnh Hạ Long	22	**0.691**	-1.505
NB16	Lạch Huyện	18	**0.641**	**0.323**
NB3	Cẩm Phả	22	**0.668**	-0.142

Nhận xét:

- **Salinity (Độ mặn):** Các trạm có $R^2 > 0.6$ chứng tỏ tính chất lan truyền độ mặn tốt, có thể dự đoán sang trạm khác rất tốt.
- **DO (Oxy):** Kém hơn hẳn (chỉ có NB15 dương) vì DO biến thiên cục bộ rất mạnh do

3. Pipeline Tích hợp Module (Data Architecture)



- Tốc độ đáp ứng: Toàn bộ chu trình cho 17 Trạm $\times$ 19 Chỉ số chỉ mất $\sim$ 200ms.

Xin Cảm Ơn!

Q&A